

## 2019150445 신백록

1.  $(x_1, x_2, \dots, x_n)$ 가 주어졌을 때 모수가 나올 가능성을 모수에 대한 함수로 나타낸 것을 **우도함수**라고 한다.

우도함수가 **maximize** 된다는 것은 **합류형일 때는** 각각의 class를 맞추는 확률이 가장 클 때이고, **회귀일 때는**  $y_i$ 값에 가장 가깝게  $\hat{y}_i$ 를 추정하는 것이다.

이것은 손실함수가 **minimize** 되는 것과 같고, 그것을 만족하는 모수  $\theta$ 를 찾는 것이 **딥러닝의 목표**이다.

2. **결함분포**는 모수가 주어졌을 때의 표본에 대한 함수이다.

반대로 **우도함수**는 표본이 주어졌을 때의 모수에 대한 함수이다.

우도함수는  $\theta$ 에 대한 함수이기 때문에 **integration**을 하면 된다.

$$f(x_1, \dots, x_n | \theta) = L(\theta | x_1, \dots, x_n) \text{로 만족한다.}$$

3. 만약  $n$ 개의 표본  $(x_1, \dots, x_n)$ 이 서로 독립적으로 추출된다면,

$$\textcircled{1} x_1, \dots, x_n \sim \text{Ber}(p_i)$$

$$\log L(p) = \log \prod_{i=1}^n p_i^{x_i} (1-p_i)^{(1-x_i)} = \sum_{i=1}^n (x_i \log p_i + (1-x_i) \log (1-p_i))$$

$\text{Ber}(p_i)$

성공횟수

$$\textcircled{2} x_1, \dots, x_n \sim \text{Bin}(r, p_i)$$

$$\log L(r, p_i) = \log \prod_{i=1}^n \binom{r}{x_i} p_i^{x_i} (1-p_i)^{r-x_i} = \sum_{i=1}^n (r \log p_i + (n-r) \log (1-p_i))$$

constant

**m개 class 각각이 나온 확률** ( $p_m = 1 - \sum_{j=1}^{m-1} p_j$ ) **class 1이 나온 횟수** ( $n_m = n - \sum_{j=1}^{m-1} n_j$ )

$\text{Multinomial}(p_1, p_2, \dots, p_{m-1})$

$$\textcircled{3} x_1, \dots, x_n \sim \text{Multinomial}(n_1, n_2, \dots, n_{m-1}, p_1, p_2, p_3, \dots, p_{m-1})$$

$$\log L(p) = \sum_{i=1}^n \log (p_1^{n_1} p_2^{n_2} \dots p_{m-1}^{n_{m-1}} p_m^{n_m}) = \sum_{i=1}^n (n_1 \log p_1 + n_2 \log p_2 + \dots + n_m \log p_m) = \sum_{i=1}^n \sum_{j=1}^m (n_j \log p_j)$$

(순서 = constant)

$$\textcircled{4} x_1, \dots, x_n \sim N(\mu_i, \sigma_i^2)$$

$$\log L(\mu, \sigma^2) = \sum_{i=1}^n \log \frac{1}{\sqrt{2\pi}\sigma_i} \exp\left(-\frac{(x_i - \mu_i)^2}{2\sigma_i^2}\right) = \sum_{i=1}^n \left( \log \frac{1}{\sqrt{2\pi}\sigma_i} - \frac{(x_i - \mu_i)^2}{2\sigma_i^2} \right)$$

4. 이항분포에서의 확률은  $p$ 로 observation마다의  $p$ 가  $i$ 에 의존하지 않고 **identical**하다.

이항분포에서의 확률은  $p_i$ 로 observation이 주어졌을 때의  $p_i$ 를 예측하고 싶어한다. (identical x)

하지만 이렇게 되면  $p_i$ 가 sample에 의존하게 되어  $p_i$ 의 추정이 불가능해진다.

따라서 특성변수  $x_i$ 를 정의하고,  $p_i$ 를 모수  $\theta$ 에 대한 함수인  $p_i = \theta x_i + b$ 로 만들면 된다.

5. Bernoulli 분포의 로그우도함수는  $p$ 가 identical해서  $\log p \cdot \sum_{i=1}^n y_i + (n - \sum_{i=1}^n y_i) \log (1-p)$ 가 되고,

binary crossentropy는  $p$ 가 identical하지 않기에  $p_i$ 로 표시하고 각각의  $x_i$ 가 주어졌을 때 모수  $\beta$ 를 추정하여  $p_i$ 를 추정하는 과정을 거친다.

다항분포는 임주가 여러 개일 때이고, Bernoulli와 마찬가지로 설명가능하다.

정규분포의 로그우도함수도  $\mu$ 가 identical한 때이고,

MSE에서의  $\mu_i = \beta x_i$ 로 identical하지 않고, 모수  $\beta$ 를 추정함으로써  $\mu_i$ 를 추정하게 된다.